Semestre I - 2022

1 Objetivos

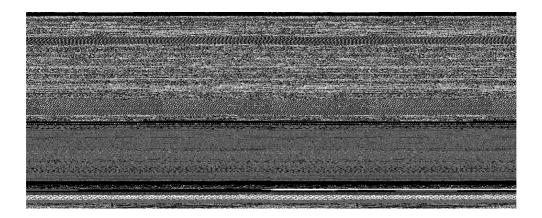
- Aplicar los conocimientos adquiridos sobre deep learning y las redes neuronales.
- Investigar y adquirir conocimientos sobre el uso de redes convolucionales para la clasificación de imágenes de malware.

2 Preámbulo

La clasificación de malware es una tarea que involucra diversos retos. Cada uno de los análisis estático y dinámico tiene sus ventajas y sus limitaciones. Del lado del análisis estático la velocidad de análisis es una ventaja y un reto consiste en diferenciar las llamadas a las DLLs y APIs sospechosas, de llamadas benignas. Del lado dinámico la ventaja es que se puede registrar el comportamiento del malware con todo detalle, pero la preparación del entorno y ejecución requiere una inversión de tiempo y recursos técnicos.

Una idea nueva ha surgido con el uso de las redes neuronales convolucionales. Estas redes se usan normalmente en la clasificación de imágenes, y de aquí surge la idea: ¿qué sucede si los bytes de un malware se pasan a una imagen? (artículo "Malware Images: Visualization and Automatic Classification").

Las siguientes imágenes son dos ejemplares distintos de malware que pertenecen a la familia Adialer.C:



Los hashes de estos ejemplares son:

- 00bb6b6a7be5402fcfce453630bfff19
- 000bde2e9a94ba41c0c111ffd80647c2

Universidad del Valle de Guatemala Facultad de Ingeniería Departamento de Ciencias de la Computación CC3094 – Security Data Science

Laboratorio #6 – Clasificación de malware con DL

Semestre I - 2022

Podemos observar a simple vista que las imágenes son bastante similares, y podemos determinar que ambos pertenecen a la misma familia. Entonces podemos considerar convertir los ejemplares de malware a imágenes y entrenar a la red neuronal con estas para la clasificación de malware.

3 Desarrollo

<u>Este laboratorio es obligatorio</u>, ya que forma parte del proyecto final del curso (sobre este laboratorio se trabajarán modelos de ataque y defensa). <u>Se deberá desarrollar de forma individual o en parejas, con la restricción de que los grupos serán los mismos para el proyecto.</u>

La entrega del laboratorio se realizará el domingo 08 de mayo a las 11:59 p.m. Se deberá entregar un notebook jupyter.

Para este laboratorio se utilizará el dataset contenido en el archivo malimg_dataset.zip que se encuentra en CANVAS. Este dataset contiene imágenes en formato .PNG de 25 familias distintas de malware.

- 1. En el preprocesamiento debe mostrar cuantos ejemplares hay por cada familia. En base a estos datos debe determinar si considera pertinente prescindir de ejemplares que tengan pocas observaciones.
- 2. Plotee las imágenes de los ejemplares de malware.
- 3. Utilizando Keras y Tensorflow construya una red neuronal con las capas, funciones de activación y el optimizador que considere conveniente.
- 4. Muestre el resumen del modelo.
- 5. Divida el dataset en un 70% entrenamiento y un 30% de pruebas.
- 6. Entrene el modelo con el número de épocas que considere conveniente.
- 7. Muestre las métricas de su modelo.
- 8. Evalúe el modelo con el dataset de pruebas y muestre las métricas obtenidas. Discuta los resultados obtenidos.